


# 让多 Agent 协作 进入确定性交付控制面





可回滚 · 可审计 · 可复算 · 失败闭合

**PRE-RELEASE**    AgentTeams Runtime    Policy Gateway    6 Skill DAG



真实 E2E 投影 · 只读运维控制台

# 初赛设想，已收敛为可验证系统

| 初赛概念模型                |                                                                                      | 复赛工程实现               |
|-----------------------|--------------------------------------------------------------------------------------|----------------------|
| 6 个逻辑角色               |    | 4 个运行时 Agent • 6 类职责 |
| 手工 handoff            |    | Controller 状态机交接     |
| 初赛旧称（不沿用）：MCP sidecar |    | GitHub MCP 隔离服务      |
| 初赛旧称（不沿用）：可观测侧车       |    | 审计与可观测平面             |
| 手工拼 Demo              |  | Preview 包 + 只读控制台    |

工程收敛，不是功能缩水

减少无收益的模型交接，把确定性职责下沉为 Skill 与状态机。

# 多 Agent 难在控制，不在生成

---

## 01 交接失控

乱序 · 重复 · 超时 · 进程崩溃

---

## 02 权限失控

Worker 接触 PAT · 高风险写入缺审批

---

## 03 证据失真

成功截图无法证明路径、状态和清理

---

**MergePilot 的答案：语义决策交给 Agent，确定性治理交给 Controller / Gateway。**

# 一条 PR 链路，三层责任边界



## 状态与证据平面



# 四个运行时 Agent，六类职责

## Manager

接入 · 路由 · 收口

## Reviewer

审查 · 风险判断

## Fixer

修复 · 受治理提交

## Verifier

复测 · 回滚判定

## Triage · Skill Stage

diff-parse + risk-classify

## Fix Planning · Planning Stage

Fixer 规划阶段 + Controller 状态

不为保持数字新增 Agent

# Skill 让工程动作可测试、可超时

01 diff-parse

解析Diff结构

02 risk-classify

分类风险与路径

03 sast-scan

确定性静态扫描

04 test-runner

有界测试执行

05 pr-lifecycle

PR创建/合并/回滚

06 case-retrieval

pgvector案例检索

Schema


Deadline

Atomic output

Fail-closed

Evidence

# 交接由状态机推进，不靠猜测



- Outbox**: 派发可重试，状态推进只发生一次。
- CAS**: late event只有命中当前状态与revision才能恢复。
- Crash recovery**: 从磁盘journal与数据库事实恢复，不依赖内存。

## 唯一状态权威

Agent runtime  
不是 durable state owner

# PAT 被锁在 GitHub MCP 隔离服务



Worker 不持 PAT · PAT 不进入日志、PPT、Trace 或 Agent 上下文




# 审计与可观测，不是一个“侧车”

|              |                                  |                  |
|--------------|----------------------------------|------------------|
| PostgreSQL   | 任务状态 · 阶段 · Outbox · 审批 · 结构化审计  | 已实现 / 已验证 (限定环境) |
| pgvector     | 案例检索 · 相似度结果 · advisory evidence | 已实现 / 离线验证       |
| MinIO        | 方向感知配置 · 对象与证据持久化                | 已实现 / 本地真实验证     |
| Trace / OTel | Controller · Gateway · Skill 关联链 | 本地 collector 已验证 |

SLS 云出口：规划 / 待接入

database\_verified=false    audit\_producer\_contract=NOT\_VERIFIED

# 失败先停住，再依据事实回滚



- 先记后写**: WAL / journal在mutation前持久化。
- 精确owner**: 锁、receipt、容器和网络按归属逆序清理。
- 保留主错误**: rollback失败不会覆盖首个稳定错误。

任何读取失败或 revision 漂  
移

不猜、不重试盲写  
直接 HOLD 升级人工

# run35: 同一运行收敛到 complete

17

阶段完成

16 / 16

前置门禁

6 / 6

路由边

2

Receipt + Matrix





`transport_profile = wsl-user-relay`

`direct_routing_verified = false`

六条边逐边验证通过，不等于内核直连路由已验证。

# 一个屏幕判断 Complete、Failed、Stale

**FAILED**

首个稳定错误  
失败阶段与路由边置顶

**STALE**

保留最后良好数据  
年龄持续推进

GET-only · loopback-only · 无写操作控件

# Preview 已变成可安装交付物



冻结门禁 · 2246 passed / 20 skipped

9

离线镜像

847.4 MB

OCI tar

200

Windows 页面 / API

0

终态残留


SAME\_MACHINE\_ACCEPTED

EXTERNAL\_BLOCKED

Pre-release · 非 Latest · 不声称 production ready

checksum / image-set gate → load → doctor → explicit Windows loopback publication

# 误报下降，但成本与校准仍需改进



**FP 21 → 9**

主要改善来自误报下降

**Token +32.95%**

API requests +80%

**不能声明 “多 Agent 必然更好”**

单模型 · 合成 fixture · 每组 10 例

# 可运行、可证明，也明确未验证什么

## 本次交付

- 01

更新方案

PPT / PDF · 逐页证据
- 02

代码包

preview.3 · 9 镜像 · checksum
- 03

Demo

现场脚本 · 录屏备份
- 04

证据矩阵

声明 · SHA · 测试 · 限制

## 下一步不是继续堆 Agent

- 外部验收：独立 Windows 11 物理机。
- 扩大证据：多仓库、更大真实样本。
- 补齐出口：SLS 云端可观测。
- 用户反馈：安装与日常使用问题。

application / database / production / revision producer / audit producer: 仍未验证